

Global Solution
DISRUPTIVE ARCHITECTURES: IOT, IOB &
GENERATIVE IA

Relatório Técnico da Global Solution 2024

Alberto R. Peruchi - RM99706

Angelo Augusto Pelluci - RM98310

Gabrielle da Silva Stanguini - RM98786

Maria Fernanda Ribeiro Melo - RM98818

Nicolas Reis do Espírito Santo - RM98819

Relatório Técnico

Identificação e Classificação de Espécies Marinhas Utilizando Deep Learning

Link para o Repositório:

<https://github.com/AngPF/GlobalSolution-IA>

Link para o Vídeo:

<https://youtu.be/Gip0ea7Jj8g>

Descrição do Problema

A preservação da biodiversidade marinha é essencial para a saúde dos ecossistemas aquáticos e para a manutenção dos serviços ambientais que estes oferecem. Com o aumento das atividades humanas nos oceanos, é crucial monitorar a presença e a distribuição das espécies marinhas para detectar possíveis ameaças, como a introdução de espécies invasoras ou a diminuição de populações nativas. Este projeto visa desenvolver um modelo de deep learning para identificar e classificar espécies marinhas em imagens subaquáticas ou superficiais. As espécies-alvo do estudo são: tartarugas marinhas e focas, por elas estarem frequentemente em perigo devido à caça, poluição e destruição de habitats. Lulas e lagostas, pois algumas espécies desses animais podem se tornar invasoras em certas regiões, competindo com as espécies nativas por recursos. Estrelas do mar e ostras pois elas são indicadores importantes da saúde dos recifes de corais e outros habitats marinhos. Água-viva, peixes dourados e outros peixes pois são frequentemente alvos da pesca excessiva e nosso sistema pode ajudar na gestão de estoques pesqueiros, garantindo que as práticas de pesca sejam sustentáveis.

Metodologia

Coleta de Dados

Para treinar o modelo, coletamos um vasto conjunto de dados de imagens contendo as espécies-alvo. As imagens foram obtidas de fontes diversas, incluindo bancos de dados públicos e imagens fornecidas por instituições de pesquisa marinha.

Pré-processamento dos Dados

1. **Rotulagem:** Cada imagem foi rotulada com a espécie correspondente conforme o arquivo de labels:
 - 0: Starfish (Estrela do mar)
 - 1: Squid (Lula)
 - 2: Sea Turtle (Tartaruga Marinha)
 - 3: Oyster (Ostra)
 - 4: Lobster (Lagosta)
 - 5: JellyFish (água-viva)
 - 6: Harbor Seal (Foca)
 - 7: GoldFish (Peixe-Dourado)
 - 8: Fish (Peixe)
2. **Redimensionamento:** As imagens foram redimensionadas para um tamanho padrão (por exemplo, 224x224 pixels) para uniformidade.
3. **Normalização:** Os valores dos pixels foram normalizados para o intervalo $[-1, 1]$.

Arquitetura do Modelo

Utilizamos uma arquitetura de rede neural convolucional (CNN) devido à sua eficácia comprovada em tarefas de classificação de imagens. A arquitetura utilizada no projeto foi implementada no arquivo **app.py**, que treina e avalia o modelo.

1. **Camadas Convolucionais:** Para extração de características.
2. **Camadas de Pooling:** Para reduzir a dimensionalidade das características extraídas.
3. **Camadas Fully Connected:** Para a classificação final das espécies.
4. **Softmax:** Na camada de saída, para obter as probabilidades de cada classe.

Treinamento

O modelo foi treinado utilizando a biblioteca **TensorFlow** (versão 2.13.1) com o backend **Keras**, que já vem integrado nessa versão. O treinamento foi realizado em um conjunto de dados dividido em 80% para treino e 20% para validação. O modelo foi treinado no Teachable Machine e salvo no arquivo **keras_model.h5**. Para testar o modelo, foi utilizado o Python 3.11.9

Avaliação do Modelo

Para avaliar o desempenho do modelo, utilizamos métricas como acurácia. Além disso, construímos uma matriz de confusão para analisar a performance em cada classe específica.

Resultados

O modelo apresentou o seguinte resultado após o treinamento e avaliação:

- Acurácia: 78%

A matriz de confusão indicou que o modelo teve um bom desempenho na maioria das classes, mas houve algumas confusões entre espécies visualmente semelhantes, como diferentes tipos de peixes.

Conclusões

O modelo desenvolvido demonstrou ser eficaz na identificação e classificação de espécies marinhas a partir de imagens. Com uma acurácia de 78%, ele pode ser uma ferramenta valiosa para monitorar a biodiversidade marinha e detectar a presença de espécies ameaçadas ou invasoras. A implementação desse modelo em sistemas de monitoramento marinho poderá fornecer dados cruciais para a conservação dos ecossistemas aquáticos e apoiar a tomada de decisões em políticas ambientais.